

● LLM ( $n=6$  models)    ■ CodeAct ( $n=5$  models)    ◆ RLM ( $n=5$  models)    - - Human baseline

