

Mean F1 vs cost (error bars = across-task std)

